

数据挖掘课程项目 - 中期进展报告

项目当前阶段：Minimum Runnable GraphRAG Baseline 已跑通，并已在真实 QASPER train split 全量数据上完成验证。GraphRAG 检索召回率和答案 F1 有提升，但延迟与拒答准确率仍需优化。

0. 项目基本信息

- 项目名称：面向计算机科学论文的证据约束型 GraphRAG 问答系统
- 项目链接：https://github.com/RouVen-crp/DataExcavate_Proj
- 小组成员与分工：

姓名	学号	组内角色	开题以来的核心贡献	中期之后的分工规划
吴雨霏	3220251395	数据与审计负责人	参与 QASPER 数据下载、清洗规则确认、数据质量审计与脏数据类型整理	扩大数据切片审计，补充 evidence mismatch、long document、unanswerable 子集分析
王文正	3120250953	数据与审计负责人	参与数据预处理验收、审计指标核对与运行结果整理	配合数据质量分析和报告图表整理，复核真实数据运行日志
唐易成	3220251363	图谱构建负责人	完成中期轻量 Rule-Based Co-Occurrence Graph，保留来源段落 ID 与 graph trace	继续推进实体/关系抽取、实体规范化、边权设计，评估是否引入 Neo4j
李昊	3220251322	检索与生成负责人	完成 TF-IDF RAG Baseline、GraphRAG 检索器、抽取式回答与拒答策略	引入 BM25 或 Dense Vector RAG 对照，优化拒答阈值与答案生成质量
牛煜雯	3220251288	评测负责人	完成 Evidence Recall@K、Answer Token F1、Refusal Accuracy、Latency 与 Failure Cases 输出	负责消融实验、指标表格、失败案例分析和最终报告实验部分

1. 项目概述与当前状态

1.1. 中期里程碑达成情况

- **开题计划目标：**项目开题时计划构建“知识图谱检索 + 路径证据推理”的问答系统，在长文本论文问答场景下降低幻觉；数据集选择 QASPER；基线包括 BM25-RAG 与 Dense Vector RAG；核心方案包括实体/关系抽取、实体规范化、子图检索、路径证据拼接和拒答机制；评估 Answer F1/EM、Evidence Precision/Recall/F1、Faithfulness、Unsupported Claim Rate、拒答准确率和平均延迟。
- **中期实际达成：**已完成一个 CPU-only、可一键复现的 Minimum Runnable GraphRAG Baseline。当前代码能通过 `run_midterm.py` 加载真实 QASPER，输出 Processed QASPER Slice、数据审计、TF-IDF RAG Baseline、Rule-Based Co-Occurrence GraphRAG、抽取式回答、拒答结果、评测指标和 Failure Cases。已先在 12 篇论文、60 个 QA 的小切片上验证闭环，再完成 train split 全量运行：888 篇论文、2593 个 QA、46882 个段落。

1.2. 代码仓库状态审计

- **提交统计：**
 - main 分支总 commit 数：28 次。
 - 开题后新增 commit 数：28 次。
 - 活跃贡献人数：5/5 人均有提交。
- **分支与协作方式：**
 - 当前主分支：`main`。
 - 远程仓库：`origin https://github.com/RouVen-crp/DataExcavate_Proj.git`。
 - Git 历史中可见 PR 合并记录，例如 `Merge pull request #9 from yezhuqiul11/main`、`Merge pull request #10 from HUAIJURENSHEN/main` 和 `Merge pull request #11 from codex/full-gasper-validation`。
- **当前仓库目录结构：**

```
.
├── AGENTS.md                # agent 工作约定
├── CONTEXT.md              # 项目领域词汇表
├── README.md               # 环境配置、一键运行命令、输出文件说明
├── __pycache__
│   └── run_midterm.cpython-314.pyc
├── docs
│   ├── COLLABORATOR_HANDOFF.md
│   ├── PROJECT_HANDOFF.md
│   ├── adr
│   ├── agent_handoff.md
│   ├── agents
│   ├── image
│   ├── 小组项目开题.pdf
│   ├── 小组项目选题和指南.pdf
│   ├── 项目中期进展报告.md
│   └── 项目中期进展报告模板.md
├── requirements.txt         # Python 测试依赖：pytest
├── run_midterm.py           # 一键运行入口，串联数据、检索、回答、评测与导出
└── run_scale_experiments.py # 分层规模实验入口
```

```

├── src/
│   ├── __init__.py
│   ├── __pycache__
│   ├── answering.py          # Evidence-Constrained Extractive Answer 与拒答
│   ├── audit.py              # 数据审计：长度、evidence 映射、unanswerable 统计
│   ├── data_loader.py        # 本地 JSON/JSONL 与官方 QASPER v0.3 下载缓存
│   └── evaluate.py           # Evidence Recall@K、Answer Token F1、Refusal Accuracy、失
败案例
├── graph_rag.py              # Rule-Based Co-Occurrence GraphRAG、trace 输出
├── preprocess.py             # QASPER 标准化、evidence 映射、Processed QASPER Slice 写出
├── retrieval.py              # TF-IDF RAG Baseline
├── tests/                    # pytest 行为测试与 smoke suite
│   ├── __pycache__
│   ├── run_smoke_tests.py
│   ├── test_audit.py
│   ├── test_data_loader.py
│   ├── test_graph_rag.py
│   ├── test_preprocess.py
│   ├── test_refusal_failures.py
│   ├── test_runner_smoke.py
│   └── test_tfidf_baseline.py

```

9 directories, 30 files

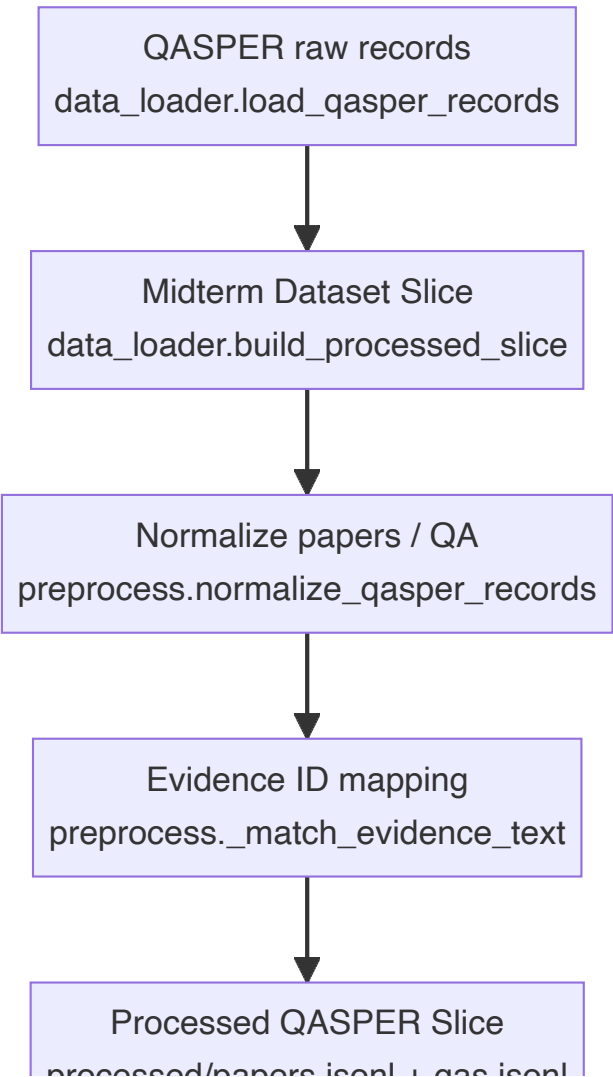
2. 数据工程与审计落地


2.1. 原始数据审计反馈

开题报告确定数据集为 QASPER，其总体规模约 1585 篇论文、5049 个问题，官方划分为 Train 888 篇、Validation 281 篇、Test 416 篇。本次中期审计先使用 QASPER train split 的 Midterm Dataset Slice：12 篇论文、60 个 QA、1053 个段落。运行输出见 `results/qasper_midterm/audit.json`。

数据问题	量化规模	解决方案（精确到文件/函数）	处理后效果
文档长度差异明显，长文档会稀释直接检索效果	12 篇论文中有 5 篇超过 4000 words；最长 7255 words，平均 3866 words	<code>src/audit.py::audit_processed_slice</code> 统计长文档； <code>src/retrieval.py::TfidfRetriever.retrieve</code> 按同一 paper 内段落级 top-k 检索	将 QA 输入从整篇论文缩小到 top-k evidence paragraphs，为 RAG 与 GraphRAG 提供可控检索空间
存在长段落，单段证据仍可能过长	1053 个段落中有 11 个超过 250 words；最长段落 499 words	<code>src/audit.py::audit_processed_slice</code> 标记长段落； <code>src/answering.py::_best_sentence</code> 在 top evidence 中选最相关句子	即使检索段落较长，回答模块也只抽取 Top Evidence Sentence Answer，减少无关上下文
部分 gold evidence 无法映射到段落 ID	60 个 QA 中有 7 个出现 evidence 缺失或不完整；共 10 条 evidence match missing；83 条 exact match，0 条 partial match	<code>src/preprocess.py::_match_evidence_text</code> 增加归一化匹配和段落子串 partial match； <code>src/audit.py</code> 输出 exact/partial/missing 计数	当前切片大多数 evidence 可 exact match；缺失样本被显式记录，避免评测时误以为是检索模型失败
QASPER 包含不可回答问题，需要拒答能力	60 个 QA 中有 11 个 unanswerable，占 18.33%；train split 全量为 278/2593，占 10.72%	<code>src/answering.py::answer_from_evidence</code> 实现 Retrieval-Based Refusal； <code>src/evaluate.py::evaluate_predictions</code> 统计 Refusal Accuracy	全量 GraphRAG Refusal Accuracy 为 22.66%，baseline 为 26.62%，说明拒答路径已可度量但仍需单独调参
开题预测的“大量 partial evidence mismatch”未明显发生	本次切片 partial_match_count = 0	保留 <code>src/preprocess.py::_match_evidence_text</code> 的 partial match 逻辑作为兼容保障	真实小切片中 evidence 多数能 exact match；后续扩大数据规模时继续观察
开题预测的“术语别名与实体歧义”尚未完全解决	当前中期版仅做 token 级 term 抽取，未统计实体别名规模	<code>src/graph_rag.py::extract_terms</code> 做基础 term 过滤；实体规范化和别名合并尚未实现	中期版可证明图增强检索闭环，但完整实体规范化需在终期补齐

2.2. 数据流与预处理管道





3. 基线模型与核心算法实现

3.1. 基线模型运行情况说明

- **开题计划基线：**BM25-RAG（关键词检索 + LLM 生成）和 Dense Vector RAG（段落向量检索 / FAISS + LLM 生成）。
- **中期已实现基线：**TF-IDF RAG Baseline。系统在每篇论文内部按段落构建 TF-IDF 表示，根据 question 检索 top-k 段落，再从 top evidence 中抽取最相关句子作为 Evidence-Constrained Extractive Answer。该实现不依赖外部 API 和 GPU，主要用于先完成可复现闭环；BM25 与 Dense Vector RAG 将作为终期增强对照。
- **运行环境：**Windows + Python 3.11 Conda 环境，CPU-only；不依赖 GPU、Neo4j、向量数据库或 LLM API key。
- **一键复现命令：**

```
python run_midterm.py --max-papers 20 --max-qas 60 --top-k 5 --output-dir results/qasper_midterm
```

- **全量验证命令：**

```
python run_midterm.py --max-papers all --max-qas all --top-k 5 --output-dir results/qasper_train_full
```

- 分层对比实验命令：

```
python run_scale_experiments.py --scale 20:60 --scale 100:300 --scale all:all --top-k 5 --output-dir results/scale_experiments
```

分层实验会在各规模子目录中保存完整 artifact，并生成 `results/scale_experiments/comparison.json`。每次单独运行还会生成 `run_summary.json`，记录实际论文数、QA 数、split、切片上限和指标摘要。

- 关键输出日志片段：

```
papers=12 gas=60 output_dir=results\gasper_midterm
baseline_recall@5=0.420 baseline_f1=0.067
graphrag_recall@5=0.460 graphrag_f1=0.083
failure_cases=2
```


- 测试验证：

```
D:\miniconda3\envs\dm\python.exe -m pytest
12 passed

D:\miniconda3\envs\dm\python.exe tests\run_smoke_tests.py
smoke tests passed
```

3.2. 核心进阶算法开发进度

开题报告中的完整核心方案是“证据约束 GraphRAG”：从论文段落抽取 Method、Dataset、Metric、Conclusion 等实体和关系，进行实体规范化，再基于问题图化执行 k-hop 子图检索，并按路径证据拼接上下文。中期阶段已实现其最小可运行版本：Rule-Based Co-Occurrence GraphRAG。它以 TF-IDF top seed evidence 为起点，从 question 和 seed paragraph 中抽取 terms，通过同段共现图做一跳扩展，收集 candidate evidence，再用 lexical score + graph bonus 重排。每条 GraphRAG 预测会保存 `graph_trace`，记录 seed evidence、query terms、expanded terms、expansion paths、candidate evidence 和 returned evidence。



模块	对应文件	状态	备注
数据预处理管道	<code>src/preprocess.py</code> 、 <code>src/data_loader.py</code>	完成	支持本地 JSON/JSONL 与官方 QASPER v0.3 下载缓存；新增 evidence exact/partial/missing match
基线模型	<code>src/retrieval.py</code>	完成	纯标准库 TF-IDF, CPU-only
核心进阶算法	<code>src/graph_rag.py</code>	完成中期版	已实现规则共现图、一跳扩展、graph bonus rerank、trace 输出；Neo4j、实体规范化、k-hop 路径评分待终期推进
回答与拒答	<code>src/answering.py</code>	完成中期版	支持抽取式回答与 Retrieval-Based Refusal
评测框架	<code>src/evaluate.py</code>	完成	Evidence Recall@K、Answer Token F1、Refusal Accuracy、Latency、Failure Cases
单元测试 / 集成测试	<code>tests/</code>	完成	12 个 pytest 用例 + 无 pytest smoke suite

4. 中期实验结果与阶段性分析

4.1. 评估指标与测试集构建

- **评测数据集规模：**真实 QASPER train split 中截取的 Midterm Dataset Slice：12 篇论文、60 个 QA、1053 个段落，用于中期主表和快速复现；同时补充分层实验与 train split 全量验证，最大规模为 888 篇论文、2593 个 QA、46882 个段落。
- **开题计划指标：**Exact Match、Token F1、Evidence Precision/Recall/F1、Faithfulness（RAGAS）、Unsupported Claim Rate、不可回答问题拒答准确率、平均响应时延。
- **中期已落地指标：**
 - Evidence Recall@5: gold evidence paragraph 是否出现在 top-5 retrieved evidence 中。
 - Answer Token F1: 预测答案与 reference answers 的 token overlap F1。
 - Refusal Accuracy: unanswerable QA 中系统是否正确输出 `INSUFFICIENT_EVIDENCE`。
 - Average Latency: 每个 query 的平均检索和回答耗时，单位为 ms。
 - 暂未落地: Exact Match、Evidence Precision/F1、RAGAS Faithfulness、Unsupported Claim Rate 和 NLI 一致性检测。这些指标需要 LLM/NLI 或更细粒度 claim 级评测，计划放到终期扩展。

4.2. 定量对比实验结果

模型方法 (Method)	Evidence Recall@5	Answer Token F1	Refusal Accuracy	平均耗时 (Latency)
TF-IDF RAG Baseline（中期替代 BM25/Dense Vector RAG）	42.00%	0.067	18.18%	0.42 ms/query
Rule-Based Co-Occurrence GraphRAG	46.00% (+4.00%)	0.083 (+0.016)	18.18% (+0.00%)	24.87 ms/query

结果说明：在 60 QA 快速复现切片中，GraphRAG 中期版相对 TF-IDF baseline 在 Evidence Recall@5 和 Answer Token F1 上有提升，Refusal Accuracy 持平，但耗时明显更高。当前 graph expansion 仍是规则共现和一跳扩展，需结合下方全量实验判断整体效果。

4.3. 扩大规模与全量验证

小切片表格来自 QASPER train split 的 12 篇论文、60 个 QA，主要用于快速复现和生成报告截图。为避免只根据小样本判断算法效果，已使用 `run_scale_experiments.py` 运行分层实验，并使用 `run_midterm.py --max-papers all --max-qas all` 完成 train split 全量验证。

代码已增加两类扩大规模入口：

验证层级	命令	用途
中期小切片	<code>python run_midterm.py --max-papers 20 --max-qas 60 ...</code>	快速复现与报告截图
分层实验	<code>python run_scale_experiments.py --scale 20:60 --scale 100:300 --scale all:all ...</code>	观察指标是否随数据规模变化
Train split 全量	<code>python run_midterm.py --max-papers all --max-qas all ...</code>	已完成：888 篇论文、2593 个 QA、46882 个段落

数据规模	TF-IDF Recall@5	GraphRAG Recall@5	TF-IDF Answer F1	GraphRAG Answer F1	TF-IDF Latency	GraphRAG Latency
12 篇论文 / 60 QA	42.00%	46.00% (+4.00%)	0.0671	0.0829 (+0.0158)	0.42 ms	24.87 ms
73 篇论文 / 300 QA	54.40%	54.40% (+0.00%)	0.0897	0.0947 (+0.0050)	0.65 ms	84.28 ms
888 篇论文 / 2593 QA	51.07%	54.55% (+3.48%)	0.0812	0.0909 (+0.0096)	3.95 ms	530.02 ms

全量结果表明，修正候选图加分后，GraphRAG 在 train split 上的 Recall@5 和 Answer Token F1 均优于 TF-IDF baseline，说明图增强路径并非只在极小样本上偶然有效。但 GraphRAG 的平均延迟显著增加，且全量 Refusal Accuracy 从 TF-IDF 的 26.62% 降至 22.66%。下一步应优先限制候选扩展范围、缓存 paper 级 lexical scores，并单独调节拒答策略。

4.4. 实验结果初步诊断与分析

#	输入 (Query 片段)	模型输出	正确答案	失败原因	改进方向
1	What are the results?	INSUFFICIENT_EVIDENCE	报告不同模型在 all data 和 subset training 下的 accuracy, 例如 ACP-BERT 0.933、ACP+AL+CA+CO-BiGRU 0.917 等	retrieval_miss: gold evidence 位于 1909.00694::p0036、p0038, 但 top-5 返回 p0026、p0042、p0019 等	改进段落排名与 graph expansion, 增加数值/结果表格相关 term 的权重
2	What are labels available in dataset for supervision?	INSUFFICIENT_EVIDENCE	negative、positive	retrieval_miss: gold evidence 为 1909.00694::p0000, 但 GraphRAG top-5 返回 p0048、p0027、p0042 等	加强 dataset/label 相关 keyphrase 抽取, 避免共现图被泛化实验段落吸走

- **总体优缺点小结:** 当前 Minimum Runnable GraphRAG Baseline 已能在真实 QASPER 小切片上复现完整结果, 并保存可解释 trace 与失败案例。GraphRAG 相比 TF-IDF 有小幅提升, 但由于图构建仍依赖规则 token 共现, 存在候选扩展过宽、语义匹配弱和 latency 上升的问题。终期阶段应优先改进 keyphrase extraction、BM25/sklearn TF-IDF baseline、graph edge weight 和拒答阈值调参。

5. 后续风险评估与冲刺排期

5.1. 风险清单动态调整

- **开题风险 1: 图谱抽取质量不足, 导致检索路径错误状态:** 部分发生。中期版尚未做完整实体/关系抽取和 Neo4j 入库, 先用规则共现图降低实现风险; 当前 GraphRAG Recall@5 相比 TF-IDF baseline 提升幅度有限, 小切片为 +4.00%, train split 全量为 +3.48%。预案: 延续开题预案, 先定义小而稳的关系模式 (Task-Method-Dataset-Metric), 小样本人审抽取质量, 保留 lexical retrieval 回退通道; 终期逐步增加实体规范化和 edge weight。
- **开题风险 2: 模型调用成本或算力受限状态:** 已规避。中期版本不依赖 LLM API、GPU、Neo4j 或 FAISS, 全部 CPU-only 运行; 代价是生成能力和语义检索能力暂未充分展开。预案: 终期若加入 LLM 生成或 Dense Vector RAG, 保持 optional 路径; 高成本环节使用缓存和小切片评测, 默认 baseline 仍保持可运行。
- **新增风险 1: GraphRAG latency 明显高于 baseline 状态:** 已发生。train split 全量运行中 GraphRAG 平均 530.02 ms/query, TF-IDF baseline 平均 3.95 ms/query。
预案: 缓存每篇论文的 lexical scores、限制 expansion terms、按 paper 预构建索引、减少全量 rerank。
- **新增风险 2: QASPER evidence 映射不完整影响评测可信度**
状态: 部分发生。60 个 QA 中有 7 个出现 evidence 缺失或不完整。
预案: 继续完善 preprocess._match_evidence_text, 引入更稳的文本归一化和 fuzzy match; 报告中单独标注 missing evidence 样本。

5.2. 终期冲刺详细排期 (第 13 周 - 第 16 周)

周次	核心任务目标	责任人	预期交付物 / 验收标准
第 13 周	完成中期提交与复核，确认 baseline、小切片实验、分层实验和 train split 全量验证结果可追溯	吴雨霏、王文正、牛煜雯；全员复核	中期报告 PDF、运行日志、 <code>results/qasper_midterm</code> 与 <code>results/scale_experiments</code> 指标表、失败案例表
第 14 周	使用 <code>run_scale_experiments.py</code> 完成分层与 train split 全量验证；对齐开题基线，补 BM25-RAG 或 Dense Vector RAG 之一；优化 lexical retrieval 与 graph expansion	李昊、唐易成	<code>comparison.json</code> 、全量运行日志、BM25/Dense 对照结果；graph edge weight / keyphrase extraction 初版；Recall@5 与 F1 对比
第 15 周	做开题规划中的 C1/C2 主对照和 A1/A2 消融实验	牛煜雯、李昊、唐易成	TF-IDF/BM25 or Dense、GraphRAG、GraphRAG without graph edges、GraphRAG without refusal 的指标表；不少于 5 个失败案例分析
第 16 周	整理最终交付和答辩材料，决定是否纳入 Neo4j / Optional LLM Enhancement	全员	最终报告、答辩 PPT、可复现命令、代码仓库清理、Demo 运行截图

6. AI 工具辅助使用记录

使用场景	AI 工具名称	具体辅助环节（精确到文件/功能）	团队审查与纠错说明
代码修改	Codex	修改 <code>src/preprocess.py</code> 、 <code>src/audit.py</code> 、 <code>src/answering.py</code> 、 <code>src/graph_rag.py</code> 、 <code>src/evaluate.py</code> 、 <code>run_midterm.py</code>	使用本地测试验证：12 个 pytest passed；真实 QASPER 小切片运行通过
开题阶段材料组织	ChatGPT / Cursor	开题报告初稿组织、技术路线梳理、实验设计检查	团队成员已进行审查与修改
中期报告结构与文字检查	Codex	对照 <code>docs/项目中期进展报告模板.md</code> 检查 <code>docs/项目中期进展报告.md</code> 的 commit 信息、实验口径、风险描述、排期和 AI 使用记录	团队成员人工定夺修改项，并复核报告内容与代码、运行日志一致

中期自查清单 (Self-Check List)（提交前逐项确认）：

代码仓库

- ✓ GitHub 仓库已设为公开，且近两周内有真实的 commit 记录？
- ✓ 仓库 README.md 包含环境配置说明和一键复现命令，他人可独立运行？
- ✓ 所有组员至少有 1 次 commit？

数据与实验

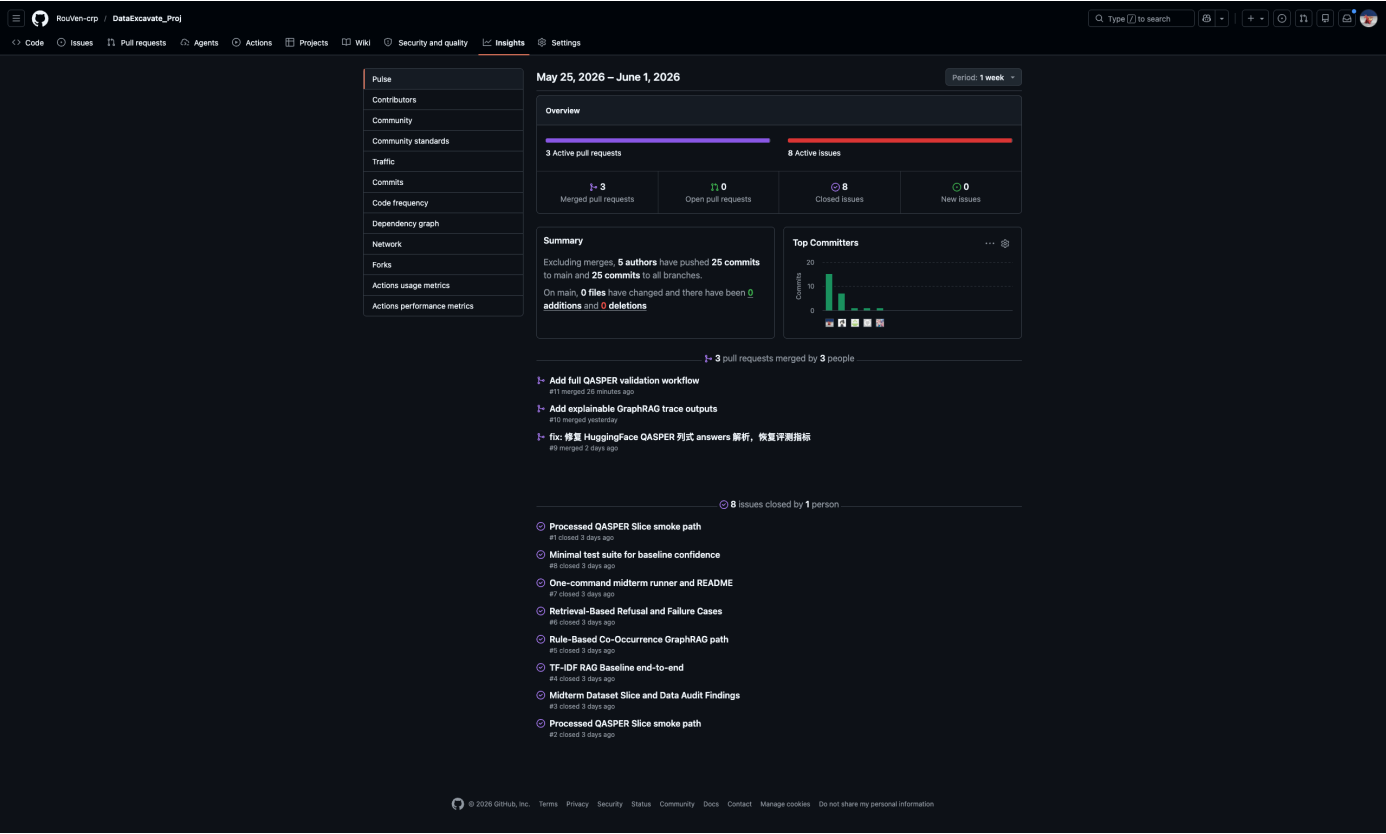
- ✓ 数据审计表已填写，每条问题都给出了量化规模（百分比/数量）？
- ✓ 基线模型已完整跑通，报告中有实际的终端输出或截图为证？
- ✓ 进阶模型与基线已进行定量对比（有数字，不只是文字描述）？
- ✓ 误差分析部分包含至少 2 个具体的失败案例？

报告完整性

- ✓ 所有成员的分工和开题后的具体贡献都明确写入了成员分工表？
- ✓ 后续冲刺排期精确到周，责任人明确，且与当前进度匹配？
- ✓ AI 工具使用情况已如实填写（未使用也须注明）？

附录：

GitHub Insights 截图



- Pulse
- Contributors
- Community
- Community standards
- Traffic
- Commits
- Code frequency
- Dependency graph
- Network
- Forks
- Actions usage metrics
- Actions performance metrics

Contributions per week to main, excluding merge commits

